

预留vTPM 需求梳理 2026-08-25

1. 一期需求列表

1.1 数据准备

1. 模型的性能数据、部署成本
2. 模型的vTPM转换系数配置

1.2 前台

1. 商品展示（模型、单价、性能保障、vTPM转换规则）
2. 购买与退款
 - a. 飞书表单提交购买意愿，合同签约
 - b. 退款规则说明
3. SLA保障说明
4. 计算器（与serverless价格折算关系）
5. 用户by模型用量看板/单个预留vTPM使用详情监控

1.3 后台

1. payload支持新类型：vTPM（与online、batch同级）
2. 购买记录配置（核心是谁购买了什么模型的多少vTPM，时间范围是多少，支持自定义多个model_name)
 - a. 考虑生命周期管理，状态流转（退款）
3. 总量监控、已售出/剩余可售出的看板、用户用量监控、单个预留vTPM使用情况监控


1.4 后端 欧阳贺明


1. 接口1：依赖后台购买记录配置数据，根据subject_id、model_name返回playgroundId以及账户购买的对应模型的预留vTPM包的信息（数组）
 - 预留vTPM包ID
 - 起止时间
 - playground_Id
 - vTPM数

- 绑定的推理端点ID
 - 优先级
2. 接口2：根据palygroundId+biz返回对应的payloads（也有优先级？）
 3. 接口3：依赖飞书表格中配置的转换系数，根据playgroundId返回一组系数
 4. 报量：vTPM的报量在meterings表中状态标记为【已预先扣费】

1.5 网关 🧑‍🚒 叶邦宇

1. 调用接口1，获取可用的预留vTPM包的信息、playgroundId
2. 调用接口2，获取可用的payloads信息
3. 调用接口3，获取转换系数，将用户的命中缓存输入、未命中缓存输入的tokens转换为vTPM
4. 滑动血槽：当前分钟级滑动窗口内，选取剩余额度最大的预留vTPM包进行消耗
 - a. 若当前预留vTPM额度不足，根据绑定端点判断是否路由到serverless（后续优化为可以直接消耗下一个预留vTPM额度）
 - b. 滑动血槽监控数据分钟级上报
5. 报量（上报本次报量的阶段性请求消耗了哪个预留vTPM包的多少额度）





2. 后续迭代内容

1. 订单打通购买、续约、库存校验、交付、后台配置、退款流程